

# 《视觉SLAM十四讲》笔记摘抄

原创 ncepu\_Chen 于 2020-04-05 19:27:01 发布 阅读量5.3w 收藏 1.8k 点赞数 422

版权

分类专栏: SLAM 文章标签: SLAM



SLAM 专栏收录该内容

754 订阅

13 篇文章

订阅专栏

## 《视觉SLAM 十四讲》笔记摘抄

### ch02 初识SLAM

经典视觉SLAM框架

SLAM问题的数学表述

### ch03 三维空间刚体运动

旋转矩阵

点和向量,坐标系

坐标系间的欧氏变换

变换矩阵与齐次坐标

齐次坐标(Homogeneous Coordinate)的优势

优势1:方便判断是否在直线或平面上

优势2:方便表示线线交点和点点共线

优势3:能够区分向量和点

优势4:能够表达无穷远点

优势5:能够简洁的表示变换

旋转向量和欧拉角

旋转向量

欧拉角

四元数

四元数的定义

用单位四元数表示旋转

### ch04 李群与李代数

李群与李代数基础

群的定义

李代数的定义

李代数 $\mathfrak{so}(3)$

李代数 $\mathfrak{se}(3)$

李群与李代数的转换关系:指数映射和对数映射

$SO(3)$ 和 $\mathfrak{so}(3)$ 间的转换关系

$SE(3)$ 和 $\mathfrak{se}(3)$ 间的转换关系

李代数求导: 引入李代数的一大动机就是方便求导优化

李群乘法与李代数加法的关系

$SO(3)$ 上的李代数求导

李代数求导

扰动模型(左乘)

$SE(3)$ 上的李代数求导

### ch05 相机与图像

针孔相机模型

畸变模型

单目相机的成像过程

### ch06 非线性优化

状态估计问题

最大后验与最大似然

最小二乘

基于观测数据 $z$ 的最小二乘

基于观测数据 $z$ 和输入数据 $u$ 的最小二乘

非线性最小二乘

一阶和二阶梯度法

高斯牛顿法

列文伯格-马夸尔特方法

### ch07 视觉里程计01

特征点匹配

特征点

根据特征点匹配计算相机运动

2D-2D匹配: 对极几何

对极约束

本质矩阵E的求解

对极几何的讨论

3D-2D匹配: PnP(Perspective-n-Point)

直接线性变换(DLT): 先求解相机位姿,再求解空间点位置

P3P: 先求解空间点位置,再求解相机位姿

Bundle Adjustment: 最小化重投影误差,同时求解空间点位置和相机位姿


3D-3D匹配: ICP

SVD方法

非线性优化方法

## ch02 初识SLAM

### 经典视觉SLAM框架



视觉SLAM流程包括以下步骤:

1. **传感器信息读取**: 在视觉SLAM中主要为相机图像信息的读取和预处理.如果是在机器人中,还可能有码盘、惯性传感器等信息的读取和同步.
2. **视觉里程计(Visual Odometry, VO)**: 视觉里程计的任务是估算相邻图像间相机的运动,以及局部地图的样子.VO又称为前端(Front End).  
视觉里程计不可避免地会出现**累积漂移**(Accumulating Drift)问题.
3. **后端优化** (Optimization): 后端接受不同时刻视觉里程计测量的相机位姿,以及回环检测的信息,对它们进行优化,得到全局一致的轨迹和地图.由于接在VO之后,又称为后端(Back End).  
在视觉 SLAM中,前端和**计算机视觉** 研究领域更为相关,比如图像的特征提取与匹配等,后端则主要是滤波与非线性优化算法.
4. **回环检测** (Loop Closing): 回环检测判断机器人是否到达过先前的位置.如果检测到回环,它会把信息提供给后端进行处理.
5. **建图** (Mapping): 它根据估计的轨迹,建立与任务要求对应的地图.

地图的形式包括**度量地图**(精确表示地图物体的位置关系)与**拓扑地图**(更强调地图元素之间的关系)两种.

### SLAM问题的数学表述

“小萝卜携带着传感器在环境中运动”,由如下两件事情描述:

1. 什么是**运动**?我们要考虑从 $k-1$ 时刻到 $k$ 时刻,小萝卜的位置 $x$ 是如何变化的.

运动方程:

$$x_k = f(x_{k-1}, u_k, w_k)$$

- $x_k, x_{k-1}$  表示小萝卜在 $k$ 和 $k-1$ 时刻的位置
- $u_k$  表示运动传感器的读数(有时也叫**输入**)
- $w_k$  表示噪声

2. 什么是**观测**?假设小萝卜在 $k$ 时刻于 $x_k$ 处探测到了某一个路标 $y_j$ ,我们要考虑这件事情是如何用数学语言来描述的.

观测方程:

$$z_{k,j} = h(y_j, x_k, v_{k,j})$$

- $z_{k,j}$  表示小萝卜在  $x_k$  位置上看到路标点  $y_j$  ,产生的观测数据
- $y_j$  表示第  $j$  个路标点
- $v_{k,j}$  表示噪声

这两个方程描述了最基本的SLAM问题:当知道运动测量的读数  $u$  ,以及传感器的读数  $z$  时,如何求解定位问题(估计  $x$  )和建图问题(估计  $y$  )?这时,我们就把SLAM问题建模成了一个**状态估计问题**:如何通过带有噪声的测量数据,估计内部的、隐藏着的状态变量?

ch03 三维空间刚体运动

旋转矩阵

点和向量,坐标系

1. 向量  $a$  在线性空间的基  $[e_1, e_2, e_3]$  下的坐标为  $[a_1, a_2, a_3]^T$ .

$$a = [e_1, e_2, e_3] \begin{bmatrix} a_1 \\ a_2 \\ a_3 \end{bmatrix} = a_1 e_1 + a_2 e_2 + a_3 e_3$$

2. 向量的内积与外积

- 向量的内积: 描述向量间的投影关系

$$a \cdot b = a^T b = \sum_{i=1}^3 a_i b_i = |a| |b| \cos \langle a, b \rangle$$

- 向量的外积: 描述向量的旋转

$$a \times b = \begin{bmatrix} i & j & k \\ a_1 & a_2 & a_3 \\ b_1 & b_2 & b_3 \end{bmatrix} = \begin{bmatrix} a_2 b_3 - a_3 b_2 \\ a_3 b_1 - a_1 b_3 \\ a_1 b_2 - a_2 b_1 \end{bmatrix} = \begin{bmatrix} 0 & -a_3 & a_2 \\ a_3 & 0 & -a_1 \\ -a_2 & a_1 & 0 \end{bmatrix} b \triangleq a^\wedge b$$

其中  $a^\wedge$  表示  $a$  的反对称矩阵

$$a^\wedge = \begin{bmatrix} 0 & -a_3 & a_2 \\ a_3 & 0 & -a_1 \\ -a_2 & a_1 & 0 \end{bmatrix}$$

坐标系间的欧氏变换

1. 欧式变换:

在欧式变换前后的两个坐标系下,同一个向量的模长和方向不发生改变,是为欧式变换.

一个欧式变换由一个旋转和一个平移组成.

2. 旋转矩阵  $R$ :

- 旋转矩阵  $R$  的推导:

设单位正交基  $[e_1, e_2, e_3]$  经过一次旋转变成了  $[e'_1, e'_2, e'_3]$ , 对于同一个向量  $a$ , 在两个坐标系下的坐标分别为  $[a_1, a_2, a_3]^T$  和  $[a'_1, a'_2, a'_3]^T$ . 根据坐标的定义:

$$[e_1, e_2, e_3] \begin{bmatrix} a_1 \\ a_2 \\ a_3 \end{bmatrix} = [e'_1, e'_2, e'_3] \begin{bmatrix} a'_1 \\ a'_2 \\ a'_3 \end{bmatrix}$$

等式左右两边同时左乘 $[e_1^T, e_2^T, e_3^T]^T$ ,得到

$$\begin{bmatrix} a_1 \\ a_2 \\ a_3 \end{bmatrix} = \begin{bmatrix} e_1^T e'_1 & e_1^T e'_2 & e_1^T e'_3 \\ e_2^T e'_1 & e_2^T e'_2 & e_2^T e'_3 \\ e_3^T e'_1 & e_3^T e'_2 & e_3^T e'_3 \end{bmatrix} \begin{bmatrix} a'_1 \\ a'_2 \\ a'_3 \end{bmatrix} \triangleq R a'$$

矩阵R描述了旋转,称为**旋转矩阵**.

◦ 旋转矩阵R的性质

1. 旋转矩阵是**行列式为1的正交矩阵**,任何行列式为1的正交矩阵也是一个旋转矩阵.所有旋转矩阵构成特殊正交群SO:

$$SO(n) = \{R \in \mathbb{R}^{n \times n} | R R^T = I, \det(R) = 1\}$$

2. 旋转矩阵是正交矩阵(其转置等于其逆),旋转矩阵的逆 $R^{-1}$ (即转置 $R^T$ )描述了一个相反的旋转.

3. 欧式变换的向量表示:

世界坐标系中的向量a,经过一次旋转(用旋转矩阵R描述)和一次平移(用平移向量t描述)后,得到了a':

$$a' = R a + t$$

## 变换矩阵与齐次坐标

1. 变换矩阵T:

在三维向量的末尾添加1,构成的四维向量称为**齐次坐标**.将旋转和平移写入**变换矩阵**T中,得到:

$$\begin{bmatrix} a' \\ 1 \end{bmatrix} = \begin{bmatrix} R & t \\ 0 & 1 \end{bmatrix} \begin{bmatrix} a \\ 1 \end{bmatrix} \triangleq T \begin{bmatrix} a \\ 1 \end{bmatrix}$$

齐次坐标的意义在于**将欧式变换表示为线性关系**.

2. 变换矩阵T的性质:

1. 变换矩阵T 构成特殊欧式群SE

$$SE(3) = \left\{ T = \begin{bmatrix} R & t \\ 0 & 1 \end{bmatrix} \in \mathbb{R}^{4 \times 4} | R \in SO(3), t \in \mathbb{R}^3 \right\}$$

2. 变换矩阵的逆表示一个反向的欧式变换

$$T^{-1} = \begin{bmatrix} R^T & -R^T t \\ 0 & 1 \end{bmatrix}$$

## 齐次坐标(Homogeneous Coordinate)的优势

**优势1:方便判断是否在直线或平面上**

若点 $p = (x, y)$ 在直线 $l = (a, b, c)$ 上,则有:

$$ax + by + c = [a, b, c]^T \cdot [x, y, 1] = l^T \cdot p' = 0$$


若点 $p = (x, y, z)$ 在平面 $A = (a, b, c, d)$ 上,则有:

$$ax + by + cz + d = [a, b, c, d]^T \cdot [x, y, z, 1] = A^T \cdot p' = 0$$

优势2:方便表示线线交点和点点共线

在齐次坐标下,

- 1. 可以用两个点p,q的齐次坐标叉乘结果表示它们的共线l.
- 2. 可以用两条直线l,m的齐次坐标叉乘结果表示它们的交点x.



这里利用叉乘的性质: 叉乘结果与两个运算向量都垂直:

- 性质1的证明:

$$l^T \cdot p = (p \times q) \cdot p = 0$$
$$l^T \cdot q = (p \times q) \cdot q = 0$$

- 性质2的证明:

$$l^T \cdot p = l^T \cdot (l \times m) = 0$$
$$m^T \cdot p = m^T \cdot (l \times m) = 0$$

优势3:能够区分向量和点

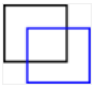


- 点(x, y, z)的齐次坐标为(x, y, z, 1)
- 向量(x, y, z)的齐次坐标为(x, y, z, 0)

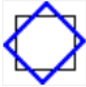
优势4:能够表达无穷远点

对于平行直线 $l = (a, b, c)$ 和 $m = (a, b, d)$ ,求取其交点的齐次坐标 $x = l \times m = (kb, -ka, 0)$ ,将其转为非齐次坐标,得到 $x = (kb/0, -ka/0) = (\inf, -\inf)$ ,这表示无穷远点.

优势5:能够简洁的表示变换

使用齐次坐标,可以将加法运算转化为乘法运算.

变换形式	图形示意	数学变换	MATLAB函数
位移(Translation)		$\begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 & t_x \\ 0 & 1 & t_y \\ 0 & 0 & 1 \end{bmatrix} * \begin{bmatrix} x \\ y \\ 1 \end{bmatrix}$	<code>imtranslate()</code>
缩放(Scale)		$\begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} = \begin{bmatrix} s_x & 0 & 0 \\ 0 & s_y & 0 \\ 0 & 0 & 1 \end{bmatrix} * \begin{bmatrix} x \\ y \\ 1 \end{bmatrix}$	<code>imresize()</code>
错切(Shear)		$\begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} = \begin{bmatrix} 1 & h_x & 0 \\ h_y & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} * \begin{bmatrix} x \\ y \\ 1 \end{bmatrix}$	

变换形式	图形示意	数学变换	MATLAB函数
旋转(Rotate)		$\begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} = \begin{bmatrix} \cos \theta & \sin \theta & 0 \\ -\sin \theta & \cos \theta & 0 \\ 0 & 0 & 1 \end{bmatrix} * \begin{bmatrix} x \\ y \\ 1 \end{bmatrix}$	<code>imrotate()</code>

旋转向量和欧拉角

旋转向量

- 旋转矩阵的缺点:
  - 旋转矩阵有9个量,但一次旋转只有3个自由度,这种表达方式是冗余的.
  - 旋转矩阵自带约束(必须是行列式为1的正交矩阵),这些约束会给估计和优化带来困难.
- 旋转向量: 任意旋转都可以用一个**旋转轴**和一个**旋转角** 来刻画.于是,我们可以使用一个向量,其**方向表示旋转轴**而**长度表示旋转角**.这种向量称为**旋转向量**(或**轴角**,Axis-Angle).

假设有一个旋转轴为n,角度为θ的旋转,其对应的旋转向量为θn.

- 旋转向量和旋转矩阵之间的转换:

设旋转向量R表示一个绕单位向量n,角度为θ的旋转.

- 旋转向量到旋转矩阵:

$$R = \cos \theta I + (1 - \cos \theta)nn^T + \sin \theta \mathbf{\hat{n}}$$

- 旋转矩阵到旋转向量:

- 旋转角 $\theta = \arccos\left(\frac{\text{tr}(R)-1}{2}\right)$
    - 旋转轴n是矩阵R特征值1对应的特征向量

欧拉角

- 欧拉角将一次旋转分解成**3个分离的转角**.常用的一种ZYX转角将任意旋转分解成以下3个轴上的转角:
  - 绕物体的Z轴旋转,得到偏航角yaw
  - 绕**旋转之后的**Y 轴旋转,得到俯仰角pitch
  - 绕**旋转之后的**X轴旋转,得到滚转角roll
- 欧拉角的一个重大缺点是**万向锁问题(奇异性问题)**: 在俯仰角为 $\pm 90^\circ$  时,第一次旋转与第三次旋转将使用同一个轴,使得系统丢失了一个自由度(由3次旋转变成了2次旋转).

四元数

为什么需要四元数: 对于三维旋转,找不到**不带奇异性的三维向量描述方式**.因此引入四元数.

四元数是一种**扩展的复数**.既是**紧凑的**,也**没有奇异性**.

四元数的定义

- 四元数的定义

一个四元数q拥有一个实部和三个虚部

$$q = q_0 + q_1 i + q_2 j + q_3 k$$

其中i,j,k,为四元数的3个虚部,它们满足以下关系式(**自己和自己的运算像复数,自己和别人的运算像叉乘**):

$$\begin{cases} i^2 = j^2 = k^2 = -1 \\ ij = k, ji = -k \\ jk = i, kj = -i \\ ki = j, ik = -j \end{cases}$$

也可以用一个标量和一个向量来表达四元数:

$$q = [s, v], \quad s = q_0 \in \mathbb{R} \quad v = [q_1, q_2, q_3]^T \in \mathbb{R}^3$$

s为四元数的实部,v为四元数的虚部.有**实四元数**和**虚四元数**的概念.

2. 四元数与旋转角度的关系:

- 在二维情况下,任意一个旋转都可以用**单位**复数来描述,乘i就是绕i轴旋转90°.
- 在三维情况下,任意一个旋转都可以用**单位**四元数来描述,乘i就是绕i轴旋转180°.

3. 单位四元数和旋转向量之间的转换:

设单位四元数q表示一个绕单位向量 $n = [n_x, n_y, n_z]^T$ ,角度为 $\theta$ 的旋转.

- 从旋转向量到单位四元数:

$$q = \left[ \cos\left(\frac{\theta}{2}\right), n \sin\left(\frac{\theta}{2}\right) \right]^T = \left[ \cos\left(\frac{\theta}{2}\right), n_x \sin\left(\frac{\theta}{2}\right), n_y \sin\left(\frac{\theta}{2}\right), n_z \sin\left(\frac{\theta}{2}\right) \right]^T$$

- 从单位四元数到旋转向量:

$$\begin{cases} \theta = 2 \arccos q_0 \\ [n_x, n_y, n_z] = [q_1, q_2, q_3]^T / \sin \frac{\theta}{2} \end{cases}$$

## 用单位四元数表示旋转

给定一个空间三维点 $p = [x, y, z] \in \mathbb{R}^3$ ,以及一个由轴角 $n, \theta$ 指定的旋转,三维点p经过旋转后变为 $p'$ .如何使用单位四元数q表达旋转?

1. 把三维空间点用一个虚四元数p表示:

$$p = [0, x, y, z] = [0, v]$$

2. 把旋转用单位四元数q表示:

$$q = \left[ \cos \frac{\theta}{2}, n \sin \frac{\theta}{2} \right]$$

3. 旋转后的点 $p'$ 可表示为:

$$p' = qpq^{-1}$$

这样得到的点 $p'$ 仍为一个纯虚四元数,其虚部的3个分量表示旋转后3D点的坐标.

只有**单位**四元数才能表示旋转,因此在程序中创建四元数后,要记得调用 `normalize()` 以将其单位化

## ch04 李群与李代数

### 李群与李代数基础

旋转矩阵构成特殊正交群 $SO(3)$ ,变换矩阵构成了特殊欧氏群 $SE(3)$ .

$$\begin{aligned}\mathrm{SO}(3) &= \left\{ \mathbf{R} \in \mathbb{R}^{3 \times 3} \mid \mathbf{R} \mathbf{R}^T = \mathbf{I}, \det(\mathbf{R}) = 1 \right\} \\ \mathrm{SE}(3) &= \left\{ \mathbf{T} = \begin{bmatrix} \mathbf{R} & \mathbf{t} \\ \mathbf{0}^T & 1 \end{bmatrix} \in \mathbb{R}^{4 \times 4} \mid \mathbf{R} \in \mathrm{SO}(3), \mathbf{t} \in \mathbb{R}^3 \right\}\end{aligned}$$

### 群的定义

- 群(Group)是一种集合加上一种运算的代数结构.把集合记作A,运算记作 $\cdot$  ,那么群可以记作 $G = (A, \cdot)$ .群要求这个运算满足如下条件(封结么逆):

- 封闭性:  $\forall a_1, a_2 \in A, \quad a_1 \cdot a_2 \in A$ .
- 结合律:  $\forall a_1, a_2, a_3 \in A, \quad (a_1 \cdot a_2) \cdot a_3 = a_1 \cdot (a_2 \cdot a_3)$
- 么元:  $\exists a_0 \in A, \quad \text{s.t.} \quad \forall a \in A, \quad a_0 \cdot a = a \cdot a_0 = a$
- 逆:  $\forall a \in A, \quad \exists a^{-1} \in A, \quad \text{s.t.} a \cdot a^{-1} = a_0$

- 李群**是指具有连续(光滑)性质的群.SO(3)和SE(3)都是李群

### 李代数的定义

每个李群都有与之对应的李代数,李代数描述了李群的局部性质.

通用的李代数的定义如下:

李代数由一个集合 $V$  ,一个数域 $F$  和一个二元运算 $[, ]$ 组成.如果它们满足以下几条性质,则称 $(V, F, [, ])$ 为一个李代数,记作 $\mathfrak{g}$ .

- 封闭性:  $\forall X, Y \in V, [X, Y] \in V$  .
- 双线性:  $\text{\$}\forall\text{forall } X,Y,Z \setminus\text{in } V, a,b \setminus\text{in } F \text{\$}$ 有:

$[aX + bY, Z] = a[X, Z] + b[Y, Z], \quad [Z, aX + bY] = a[Z, X] + b[Z, Y]$
- 自反性:  $\forall X, \in V, [X, X] = 0$ .
- 雅可比等价 $\forall X, Y, Z \in V, \quad [X, [Y, Z]] + [Z, [X, Y]] + [Y, [Z, X]] = 0$ .

其中的二元运算 $[, ]$ 被称为**李括号**.例如三维向量空间 $\mathbb{R}^3$ 上定义的叉积 $\times$ 是一种李括号.

#### 李代数 $\mathfrak{so}(3)$

- 李群 $\mathrm{SO}(3)$ 对应的李代数 $\mathfrak{so}(3)$ 是定义在 $\mathbb{R}^3$ 上的向量,记作 $\phi$ .

$$\mathfrak{so}(3) = \left\{ \phi \in \mathbb{R}^3, \Phi = \phi^\wedge = \begin{bmatrix} 0 & -\phi_3 & \phi_2 \\ \phi_3 & 0 & -\phi_1 \\ -\phi_2 & \phi_1 & 0 \end{bmatrix} \in \mathbb{R}^{3 \times 3} \right\}$$

- 李代数 $\mathfrak{so}(3)$ 的李括号为

$$[\phi_1, \phi_2] = (\Phi_1 \Phi_2 - \Phi_2 \Phi_1)^\vee$$

其中 $^\vee$ 是 $^\wedge$ 的逆运算,表示将反对称矩阵还原为向量

- $\mathfrak{so}(3)$ 和 $\mathrm{SO}(3)$ 间的映射关系为

$$\begin{aligned}\text{李群}\mathbf{R} &= \exp(\phi^\wedge) = \exp(\Phi) \\ \text{李代数}\phi &= \ln(\mathbf{R})^\vee\end{aligned}$$

#### 李代数 $\mathfrak{se}(3)$

- 类似地,李群 $\mathrm{SE}(3)$ 的李代数 $\mathfrak{se}(3)$ 是定义在 $\mathbb{R}^6$ 上上的向量.记作 $\xi$ :

$$\mathfrak{se}(3) = \left\{ \xi = \begin{bmatrix} \rho \\ \phi \end{bmatrix} \in \mathbb{R}^6, \rho \in \mathbb{R}^3, \phi \in \mathfrak{so}(3), \xi^\wedge = \begin{bmatrix} \phi^\wedge & \rho \\ \mathbf{0}^T & 0 \end{bmatrix} \in \mathbb{R}^{4 \times 4} \right\}$$



$\mathfrak{se}(3)$ 中的每个元素 $\xi$ ,是一个六维向量.前三维 $\rho$ 表示平移;后三维 $\phi$ 表示旋转,本质上是 $\mathfrak{so}(3)$ 元素.

- 在这里同样使用 $\wedge$ 符号将六维向量扩展成为四维矩阵,但不再表示反对称

$$\xi^\wedge = \begin{bmatrix} \phi^\wedge & \rho \\ 0^T & 0 \end{bmatrix} \in \mathbb{R}^{4 \times 4}$$

- 李代数 $\mathfrak{se}(3)$ 的李括号和 $\mathfrak{so}(3)$ 类似:

$$[\xi_1, \xi_2] = (\xi_1^\wedge \xi_2^\wedge - \xi_2^\wedge \xi_1^\wedge)^\vee$$

- $\mathfrak{se}(3)$ 和 $SE(3)$ 间映射关系为

$$\begin{aligned} \text{李群 } T &= \exp(\xi^\wedge) \\ \text{李代数 } \xi &= \ln(T)^\vee \end{aligned}$$

## 李群与李代数的转换关系:指数映射和对数映射

### SO(3)和 $\mathfrak{so}(3)$ 间的转换关系

- 将三维向量 $\phi$ 分解为其模长 $\theta$ 和方向向量 $\alpha$ ,即 $\phi = \theta\alpha$ .则从 $\mathfrak{so}(3)$ 到 $SO(3)$ 的**指数映射**可表示为:

$$R = \exp(\phi) = \exp(\theta\alpha^\wedge) = \cos\theta I + (1 - \cos\theta)\alpha\alpha^T + \sin\theta\alpha^\wedge$$

上式即为旋转向量到旋转矩阵的罗德里格斯公式,可见\*\* $\mathfrak{so}(3)$ 本质上是旋转向量组成的空间\*\*.

- 从 $SO(3)$ 到 $\mathfrak{so}(3)$ 的**对数映射**可表示为:

$$\phi = \ln(R)^\vee$$

实际计算时可以通过迹的性质分别求出转角 $\theta$ 和转轴 $\alpha$

$$\theta = \arccos \frac{\text{tr}(R) - 1}{2}, \quad R\alpha = \alpha$$

### SE(3)和 $\mathfrak{se}(3)$ 间的转换关系

- 从 $\mathfrak{se}(3)$ 到 $SE(3)$ 的**指数映射**可表示为:

$$T = \exp(\xi^\wedge) = \begin{bmatrix} R & J\rho \\ 0^T & 1 \end{bmatrix}$$

其中

$$J = \frac{\sin\theta}{\theta} I + (1 - \frac{\sin\theta}{\theta})\alpha\alpha^T + \frac{1 - \cos\theta}{\theta}\alpha^\wedge$$


可以看到,平移部分经过指数映射之后,发生了一次以 $J$ 为系数矩阵的线性变换.

- 从 $SE(3)$ 到 $\mathfrak{se}(3)$ 的**对数映射**可表示为:


$$\xi = \ln(T)^\vee$$

实际计算时 $\phi$ 可以由 $SO(3)$ 到 $\mathfrak{so}(3)$ 的映射得到, $\rho$ 可以由 $t = J\rho$ 计算得到.

### 三维旋转



### 三维变换



## 李代数求导: 引入李代数的一大动机就是方便求导优化

### 李群乘法与李代数加法的关系

#### 1. BCH公式及其近似形式

- 很遗憾地,李群乘积和李代数加法并不等价,即:

$$R_1 R_2 = \exp(\phi_1^\wedge) \exp(\phi_2^\wedge) \neq \exp((\phi_1 + \phi_2)^\wedge)$$

李群乘积与李代数运算的对应关系由BCH公式给出:

$$\ln(\exp(A) \exp(B)) = A + B + \frac{1}{2} [A, B] + \frac{1}{12} [A, [A, B]] - \frac{1}{12} [B, [A, B]] + \dots$$

上式中 $[\cdot, \cdot]$ 表示李括号运算.

- 当 $\phi_1$ 或 $\phi_2$ 为小量时,可以对BCH公式进行线性近似,得到李群乘积对应的李代数的表达式:

$$R_1 \cdot R_2 \text{ 对应的李代数} = \ln(\exp(\phi_1^\wedge) \exp(\phi_2^\wedge))^\vee \approx \begin{cases} J_l(\phi_2)^{-1} \phi_1 + \phi_2 & \text{当 } \phi_1 \text{ 为小量时} \\ J_r(\phi_1)^{-1} \phi_2 + \phi_1 & \text{当 } \phi_2 \text{ 为小量时} \end{cases}$$

其中左乘雅可比矩阵 $J_l$ 即为从 $SE(3)$ 到 $\mathfrak{se}(3)$ 对数映射中的雅可比矩阵

$$J_l = \frac{\sin \theta}{\theta} I + \left(1 - \frac{\sin \theta}{\theta}\right) \alpha \alpha^T + \frac{1 - \cos \theta}{\theta} \alpha^\wedge$$

其逆为

$$J_l^{-1} = \frac{\theta}{2} \cot \frac{\theta}{2} I + \left(1 - \frac{\theta}{2} \cot \frac{\theta}{2}\right) \alpha \alpha^T + \frac{\theta}{2} \alpha^\wedge$$

右乘雅可比矩阵只需对自变量取负号即可

$$J_r(\phi) = J_l(-\phi)$$

#### 2. 李群 $SO(3)$ 乘法与李代数 $\mathfrak{so}(3)$ 加法的关系:

- 对旋转 $R$ (李代数为 $\phi$ )左乘一个微小旋转 $\Delta R$ (李代数为 $\Delta \phi$ ),得到的旋转李群 $\Delta R \cdot R$ 对应的李代数为:

$$\Delta R \cdot R \text{ 对应的李代数} = \ln(\exp(\Delta \phi^\wedge) \exp(\phi^\wedge)) = \phi + J_l^{-1}(\phi) \Delta \phi$$

- 反之,李代数加法 $(\phi + \Delta\phi)$ 对应的李群元素可表示为:

$$(\phi + \Delta\phi)\text{对应的李群} = \exp((\phi + \Delta\phi)^\wedge) = \exp((J_l \Delta\phi)^\wedge) \exp(\phi^\wedge) = \exp(\phi^\wedge) \exp((J_r \Delta\phi)^\wedge)$$

3. 同理,李群SE(3)乘法与李代数se(3)加法的关系:

$$\begin{aligned} \exp(\Delta\xi^\wedge) \exp(\xi^\wedge) &\approx \exp((J_l^{-1} \Delta\xi + \xi)^\wedge) \\ \exp(\xi^\wedge) \exp(\Delta\xi^\wedge) &\approx \exp((J_r^{-1} \Delta\xi + \xi)^\wedge) \end{aligned}$$

## SO(3)上的李代数求导

对空间点p进行旋转,得到Rp,旋转之后点的坐标对旋转的导数可表示为:

$$\frac{\partial(Rp)}{\partial R}$$

对于上式的求导,有两种方式:

1. 用李代数 $\phi$ 表示姿态R,然后根据李代数加法对 $\phi$ 求导.
2. 用李代数 $\phi$ 表示微小扰动 $\partial R$ ,然后根据李群左乘对 $\phi$ 求导.

其中扰动模型表达式简单,更为实用.

## 李代数求导

用李代数 $\phi$ 表示姿态R,求导得到

$$\frac{\partial(Rp)}{\partial R} = \frac{\partial(\exp(\phi^\wedge)p)}{\partial \phi} = -(Rp)^\wedge J_l$$

## 扰动模型(左乘)

另一种求导方式是对R进行一次左乘扰动 $\partial R$ ,设左乘扰动 $\partial R$ 对应的李代数为 $\phi$ ,对 $\phi$ 求导,得到

$$\frac{\partial(Rp)}{\partial R} = \frac{\exp((\phi + \phi)^\wedge)p - \exp(\phi^\wedge)p}{\phi} = -(Rp)^\wedge$$


## SE(3)上的李代数求导

类似地,空间点p经过变换T得到Tp,给T左乘一个扰动 $\Delta T = \exp(\delta\xi^\wedge)$ ,则有

$$\frac{\partial(Rp)}{\delta\xi} = \begin{bmatrix} I & -(Rp + t)^\wedge \\ 0^T & 0^T \end{bmatrix} = (TP)^\odot$$

## ch05 相机与图像

### 针孔相机模型



O - x - y - z为相机坐标系,现实空间点P的相机坐标为 $[X, Y, Z]^T$ ,投影到O' - x' - y'平面上的点P',坐标为 $[X', Y', Z']^T$ .

- 将成像平面对称到相机前方,根据几何相似关系 $\frac{Z}{f} = \frac{X}{X'} = \frac{Y}{Y'}$ ,整理得到投影点P'在投影平面上的坐标 $P' = [X', Y']$ :

$$\begin{cases} X' = f \frac{X}{Z} \\ Y' = f \frac{Y}{Z} \end{cases}$$

- 转换得到投影点P'在像素平面上的**像素坐标** $P_{u,v} = [u, v]^T$

$$\begin{cases} u = \alpha X' + c_x = f_x \frac{X}{Z} + c_x \\ v = \beta Y' + c_y = f_y \frac{Y}{Z} + c_y \end{cases}$$

上式中 $u, v, c_x, c_y, f_x, f_y$  的单位为像素,  $\alpha, \beta$  的单位为像素/米.

- 将上式写成矩阵形式,得到\*\*现实空间点相机坐标P 和投影点像素坐标 $P_{uv}$  \*\*之间的关系:

$$Z P_{uv} = Z \begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = \begin{bmatrix} f_x & 0 & c_x \\ 0 & f_y & c_y \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} X \\ Y \\ Z \end{bmatrix} \triangleq K P$$

其中矩阵K称为相机的**内参数矩阵**.


- 上式中的P 为现实空间点在相机坐标系下的**相机坐标**,将其转为**世界坐标** $P_W$ , 有

$$Z P_{uv} = K(R P_W + t) = K T P_W$$

因此 $R, t$ (或 $T$ )又称为相机的**外参数**.

- 将最后一维进行**归一化处理**,得到点P 在归一化平面的**归一化坐标** $P_c = [X/Z, Y/Z, 1]^T$

$$P_c = \frac{P}{Z} = K^{-1} P_{uv}$$



参数矩阵有内参数K和外参数 $R, t$ ,其中:

1. 内参数矩阵K体现了**归一化相机坐标到像素坐标**的变换.

之所以是**归一化坐标**,这体现了投影性质:在某一条直线上的**空间点**,最终会投影到同一**像素点**上.

2. 外参数矩阵 $R, t$ (或 $T$ )体现了**世界坐标到相机坐标**的变换.

## 畸变模型

畸变包含两种: **径向畸变**和**切向畸变**.

- **径向畸变**: 由透镜形状引起,主要包括**桶形畸变**和**枕形畸变**.

可以看成坐标点沿着长度方向发生了变化,也就是其距离原点的长度发生了变化.

$$\begin{aligned} x_{\text{distorted}} &= x(1 + k_1 r^2 + k_2 r^4 + k_3 r^6) \\ y_{\text{distorted}} &= y(1 + k_1 r^2 + k_2 r^4 + k_3 r^6) \end{aligned}$$

- **切向畸变**: 由透镜和成像平面不严格平行引起.

可以看成坐标点沿着切线方向发生了变化, 也就是水平夹角发生了变化.

$$\begin{aligned}x_{\text{distorted}} &= x + 2p_1 xy + p_2 (r^2 + 2x^2) \\y_{\text{distorted}} &= y + p_1 (r^2 + 2y^2) + 2p_2 xy\end{aligned}$$

## 单目相机的成像过程

单目相机的成像过程:

1. 世界坐标系下有一个固定的原点P, 其**世界坐标** $P_W$
2. 由于相机在运动, 它的运动由R, t或变换矩阵 $T \in SE(3)$ 描述. 原点P 的**相机坐标** $\tilde{P}_c = RP_W + t$
3. 这时 $\tilde{P}_c$  的分量为X, Y, Z, 把它们投影到归一化平面 $Z = 1$ 上, 得到P 的**归一化相机坐标** $P_c = \frac{\tilde{P}_c}{Z} = [\frac{X}{Z}, \frac{Y}{Z}, 1]^T$
4. 有畸变时, 根据畸变参数计算 $P_c$  发生畸变后的归一化相机坐标
5. P 的**归一化相机坐标** $P_c$  经过内参K后, 对应到它的**像素坐标** $P_{uv} = KP_c$

在讨论相机成像模型时, 我们一共谈到了四种坐标: **世界坐标**、**相机坐标**、**归一化相机坐标**和**像素坐标**. 请读者厘清它们的关系, 它反映了整个成像的过程.

## ch06 非线性优化

### 状态估计问题

#### 最大后验与最大似然

SLAM模型由状态方程和运动方程构成:

$$\begin{cases}x_k = f(x_{k-1}, u_k, w_k) \\ z_{k,j} = h(y_j, x_k, v_{k,j})\end{cases}$$

通常假设两个噪声项 $w_k, v_{k,j}$  满足零均值的高斯分布:

$$w_k \sim \mathcal{N}(0, R_k), \quad v_{k,j} \sim \mathcal{N}(0, Q_{k,j})$$

对机器人的估计, 本质上就是已知**输入数据**u和**观测数据**z的条件下, 求机器人位姿x和路标点y的条件概率分布:

$$P(x, y | z, u)$$

利用贝叶斯法则, 有:

$$P(x, y | z, u) = \frac{P(z, u | x, y)P(x, y)}{P(z, u)} \propto P(z, u | x, y)P(x, y)$$

其中 $P(x, y | z, u)$ 为**后验概率**,  $P(z, u | x, y)$ 为**似然**,  $P(x, y)$ 为**先验**, 上式可表述为**后验概率**  $\propto$  **似然**  $\cdot$  **先验**. **直接求后验分布是困难的, 但是求一个状态最优估计, 使得在该状态下后验概率最大化则是可行的:**

$$(x, y)_{\text{MAP}}^* = \arg \max P(x, y | z, u) = \arg \max P(z, u | x, y)P(x, y)$$

求解**最大后验概率相当于最大化似然和先验的乘积**. 因为x, y未知, 即不知道先验, 则可以求最大似然估计:

$$(x, y)_{\text{MLE}}^* = \arg \max P(z, u | x, y)$$

最大似然估计的直观意义为: **在什么样的状态下, 最可能产生现在观测到的数据.**

### 最小二乘

#### 基于观测数据z的最小二乘

对于某一次观测

$$z_{k,j} = h(y_j, x_k) + v_{k,j}$$

由于假设噪声 $v_{k,j} \sim \mathcal{N}(0, Q_{k,j})$ ,则观测数据 $z_{j,k}$ 的似然为

$$P\left(z_{j,k} | x_k, y_j\right)=\mathcal{N}\left(h\left(y_j, x_k\right), Q_{k,j}\right)$$

将上式代入高斯分布表达式中,并取负对数,得到

$$\begin{aligned}\left(x_k, y_j\right)^* &= \arg \max \mathcal{N}\left(h\left(y_j, x_k\right), Q_{k,j}\right) \\ &= \arg \min \left(\left(z_{k,j}-h\left(x_k, y_j\right)\right)^T Q_{k,j}^{-1}\left(z_{k,j}-h\left(x_k, y_j\right)\right)\right)\end{aligned}$$

上式等价于最小化噪声项(即误差)的一个二次型,其中 $Q_{k,j}^{-1}$ 称为**信息矩阵**,即高斯分布协方差矩阵的逆.

### 基于观测数据z和输入数据u的最小二乘

因为观测z和输入u是独立的,因此可对z和u的联合似然进行因式分解:

$$P\left(x, y | z, u\right)=\prod_k P\left(u_k | x_{k-1}, x_k\right) \prod_{k, j} P\left(z_{j, k} | x_k, y_j\right)$$

定义输入和观测数据与模型之间的误差:

$$\begin{aligned}e_{u, k} &= x_k-f\left(x_{k-1}, u_k\right) \\ e_{z, j, k} &= z_{k, j}-h\left(x_k, y_j\right)\end{aligned}$$

定义

$$J(x, y)=\sum_k e_{u, k}^T R_k^{-1} e_{u, k}+\sum_k \sum_j e_{z, k, j}^T Q_{k, j}^{-1} e_{z, k, j}$$

则有

$$\left(x_k, y_j\right)^*=\arg \min J(x, y)$$

### 非线性最小二乘

对于非线性最小二乘问题:

$$\min_x F(x)=\frac{1}{2}||f(x)||_2^2$$

求解该问题的具体步骤如下:

- 给定某个初始值 $x_0$
- 对于第k次迭代,寻找一个增量 $\Delta x_k$ ,使得 $||F\left(x_k+\Delta x_k\right)||_2^2$ 达到极小值
- 若 $\Delta x_k$ 足够小,则停止
- 否则,令 $x_{k+1}=x_k+\Delta x_k$ ,返回第2步

这样,最小二乘问题被转化为一个不断寻找下降增量 $\Delta x_k$ 的问题.,具体有以下方法

#### 一阶和二阶梯度法

将目标 **函数**  $F(x)$ 在 $x_k$  附近进行泰勒展开

$$F\left(x_k+\Delta x_k\right) \approx F\left(x_k\right)+J\left(x_k\right)^T \Delta x_k+\frac{1}{2} \Delta x_k^T H\left(x_k\right) x_k$$

其中 $J(x)$ 是 $F(x)$ 关于 $x$ 的一阶导数矩阵, $H(x)$ 是 $F(x)$ 关于 $x$ 的二阶导数矩阵.

- 若 $\Delta x_k$ 取一阶导数,则

$$\Delta \mathbf{x}_k^* = -\mathbf{J}(\mathbf{x}_k)$$

- 若 $\Delta \mathbf{x}_k$ 取二阶导数,则

$$\Delta \mathbf{x}_k^* = \arg \min \left( \mathbf{F}(\mathbf{x}_k) + \mathbf{J}(\mathbf{x}_k)^T \Delta \mathbf{x}_k + \frac{1}{2} \Delta \mathbf{x}_k^T \mathbf{H}(\mathbf{x}_k) \Delta \mathbf{x}_k \right)$$

令上式对 $\Delta \mathbf{x}_k$ 导数等于0,则 $\Delta \mathbf{x}_k^*$ 可以取 $\mathbf{H} \Delta \mathbf{x}_k = -\mathbf{J}$ 的解.

## 高斯牛顿法

将 $f(\mathbf{x}_k)$ 而非 $F(\mathbf{x}_k)$ 在 $\mathbf{x}_k$ 附近进行泰勒展开

$$f(\mathbf{x}_k + \Delta \mathbf{x}_k) \approx f(\mathbf{x}_k) + \mathbf{J}(\mathbf{x}_k)^T \Delta \mathbf{x}_k$$

则

$$\Delta \mathbf{x}_k^* = \arg \min_{\Delta \mathbf{x}_k} \frac{1}{2} \|f(\mathbf{x}_k) + \mathbf{J}(\mathbf{x}_k)^T \Delta \mathbf{x}_k\|^2$$

令上式对 $\Delta \mathbf{x}$ 的导数为0,得到**高斯牛顿方程**

$$\mathbf{J}(\mathbf{x}_k) f(\mathbf{x}_k) + \mathbf{J}(\mathbf{x}_k) \mathbf{J}^T(\mathbf{x}_k) \Delta \mathbf{x}_k = 0$$

令 $\mathbf{H}(\mathbf{x}) = \mathbf{J}(\mathbf{x}) \mathbf{J}^T(\mathbf{x})$ ,  $\mathbf{g}(\mathbf{x}) = -\mathbf{J}(\mathbf{x}) f(\mathbf{x})$ , 则 $\Delta \mathbf{x}_k^*$ 可以取 $\mathbf{H} \Delta \mathbf{x}_k = \mathbf{g}$ 的解.

## 列文伯格-马夸尔特方法

泰勒展开只能在展开点附近才有较好的近似效果,因此应给 $\Delta \mathbf{x}$ 添加一个范围,称为**信赖区域**.

定义一个指标 $\rho$ 刻画这个近似的好坏程度,其分子为实际函数下降的值,分母是近似模型下降的值:

$$\rho = \frac{f(\mathbf{x} + \Delta \mathbf{x}) - f(\mathbf{x})}{\mathbf{J}(\mathbf{x})^T \Delta \mathbf{x}}$$

通过调整 $\rho$ 来确定信赖区域:

- 若 $\rho$ 接近1,则近似是最好的.
- 若 $\rho$ 太小,说明实际下降的值远小于近似下降的值,则认为近似比较差,需要缩小近似范围.
- 若 $\rho$ 太大,说明实际下降的比预计的更大,我们可以放大近似范围.

改良版的非线性优化框架如下:

1. 给定初始值 $\mathbf{x}_0$ ,以及初始优化半径 $\mu$
2. 对于第 $k$ 次迭代,求解:

$$\min_{\Delta \mathbf{x}_k} \frac{1}{2} \|f(\mathbf{x}_k) + \mathbf{J}(\mathbf{x}_k)^T \Delta \mathbf{x}_k\|^2 \quad \text{s.t.} \|D \Delta \mathbf{x}_k\|^2 \leq \mu$$

其中, $\mu$ 是信赖区域的半径, $D$ 为系数矩阵

3. 计算 $\rho$
4. 若 $\rho > \frac{3}{4}$  则 $\mu = 2\mu$
5. 若 $\rho < \frac{1}{4}$  则 $\mu = 0.5\mu$
6. 若 $\rho$ 大于某阈值,则认为近似可行.令 $\mathbf{x}_{k+1} = \mathbf{x}_k + \Delta \mathbf{x}_k$
7. 判断算法是否收敛.如不收敛则返回第2步,否则结束.

第2步中 $\Delta \mathbf{x}_k$ 的求解要使用拉格朗日乘数法:

$$\mathcal{L}(\Delta \mathbf{x}_k, \lambda) = \frac{1}{2} \|\mathbf{f}(\mathbf{x}_k) + \mathbf{J}(\mathbf{x}_k)^T \Delta \mathbf{x}_k\|^2 + \frac{\lambda}{2} (\|\mathbf{D} \Delta \mathbf{x}_k\|^2 - \mu)$$

令上式对 $\Delta \mathbf{x}_k$  导数为0,得到

$$(\mathbf{H} + \lambda \mathbf{D}^T \mathbf{D}) \Delta \mathbf{x}_k = \mathbf{g}$$

考虑简化形式,即 $\mathbf{D} = \mathbf{I}$ ,则相当于求解

$$(\mathbf{H} + \lambda \mathbf{I}) \Delta \mathbf{x}_k = \mathbf{g}$$

- 当 $\lambda$ 较小时, $\mathbf{H}$ 占主要地位,这说明二次近似模型在该范围内是比较好的,列文伯格-马夸尔特方法更接近于高斯牛顿法.
- 当 $\lambda$ 比较大时, $\lambda \mathbf{I}$ 占据主要地位,这说明二次近似模型在该范围内不够好,列文伯格-马夸尔特方法更接近于一阶梯度下降法.

## 文章目录

### ch02 初识SLAM

经典视觉SLAM框架

SLAM问题的数学表述

### ch03 三维空间刚体运动

旋转矩阵

点和向量,坐标系

坐标系间的欧氏变换

变换矩阵与齐次坐标

齐次坐标(Homogeneous Coordinate)的优势

优势1:方便判断是否在直线或平面上

优势2:方便表示线线交点和点点共线

优势3:能够区分向量和点

优势4:能够表达无穷远点

优势5:能够简洁的表示变换

旋转向量和欧拉角

旋转向量

欧拉角

四元数

四元数的定义

用单位四元数表示旋转

### ch04 李群与李代数

李群与李代数基础

群的定义

李代数的定义

李代数 $\mathfrak{so}(3)$

李代数 $\mathfrak{se}(3)$

李群与李代数的转换关系:指数映射和对数映射

$\text{SO}(3)$ 和 $\mathfrak{so}(3)$ 间的转换关系

$\text{SE}(3)$ 和 $\mathfrak{se}(3)$ 间的转换关系

李代数求导: 引入李代数的一大动机就是方便求导优化

李群乘法与李代数加法的关系

$\text{SO}(3)$ 上的李代数求导

李代数求导

扰动模型(左乘)

$\text{SE}(3)$ 上的李代数求导

### ch05 相机与图像

针孔相机模型

畸变模型

单目相机的成像过程

### ch06 非线性优化

状态估计问题

最大后验与最大似然

最小二乘

基于观测数据 $\mathbf{z}$ 的最小二乘



基于观测数据 $z$ 和输入数据 $u$ 的最小二乘

非线性最小二乘

一阶和二阶梯度法

高斯牛顿法

列文伯格-马夸尔特方法

ch07 视觉里程计01

特征点匹配

特征点

根据特征点匹配计算相机运动

2D-2D匹配: 对极几何

对极约束

本质矩阵 $E$ 的求解

对极几何的讨论

3D-2D匹配: PnP(Perspective-n-Point)

直接线性变换(DLT): 先求解相机位姿,再求解空间点位置

P3P: 先求解空间点位置,再求解相机位姿

Bundle Adjustment: 最小化重投影误差,同时求解空间点位置和相机位姿

3D-3D匹配: ICP

SVD方法

非线性优化方法

## ch07 视觉里程计01

### 特征点匹配

#### 特征点

#### 根据特征点匹配计算相机运动

根据特征点匹配计算相机运动.根据相机的成像原理不同,分为以下3种情况:

1. 当相机为单目时,我们只知道匹配点的像素坐标,是为2D-2D匹配,使用对极几何求解.
2. 当相机为双目或RGB-D时,我们就知道匹配点的像素坐标和深度坐标,是为3D-3D匹配,使用ICP求解.
3. 如果有3D点及其在相机的投影位置,也能估计相机的运动,是为3D-2D匹配,使用PnP求解.

#### 2D-2D匹配: 对极几何

##### 对极约束

[外链图片转存失败,源站可能有防盗链机制,建议将图片保存下来直接上传(img-QVwt5blH-1587570602884)(1587436458419.png)]{height="50%" width="50%"}

假设我们要求取两帧图像 $I_1, I_2$ 之间的运动,设第一帧到第二帧的运动为 $R, t$ ,两个相机中心分别为 $O_1, O_2$ .考虑 $I_1$ 中有一个特征点 $p_1$ ,它在 $I_2$ 中对应着特征点 $p_2$ .连线 $\overrightarrow{O_1 p_1}$ 和 $\overrightarrow{O_2 p_2}$ 在三维空间中交于点 $P$ ,这时点 $O_1, O_2, P$ 三个点可以确定一个平面,称为**极平面**. $O_1 O_2$ 连线与像平面 $I_1, I_2$ 的交点分别为 $e_1, e_2$ . $e_1, e_2$ 称为极点, $O_1 O_2$ 称为基线,极平面与两个像平面 $I_1, I_2$ 之间的相交线 $l_1, l_2$ 称为极线.

$P$ 在 $I_1$ 下的相机坐标为 $P = [X, Y, Z]^T$ ,两个投影像素点 $p_1, p_2$ 的像素位置为 $s_1 p_1 = K P, s_2 p_2 = K (R P + t)$ .

取 $p_1, p_2$ 的归一化坐标 $x_1 = K^{-1} p_1, x_1 = K^{-1} p_2$ ,则可以推得 $x_2 \simeq R x_1 + t$ .上式中 $\simeq$ 表示尺度意义上相等,即在齐次坐标下是相等的,物理上表示对原点成投影关系.

经过推导,得到:

$$x_2^T t^{\wedge} R x_1 = 0 \quad (1)$$

代入 $p_1, p_2$ ,得到:

$$p_2^T K^{-T} t^{\wedge} R K^{-1} p_1 \quad (2)$$

式(1)和式(2)都称为对极约束,定义基础矩阵 $F$ 和本质矩阵 $E$ ,可以进一步简化对极约束:

$$\mathbf{E} = \mathbf{t}^\wedge \mathbf{R} \quad \mathbf{F} = \mathbf{K}^{-\mathrm{T}} \mathbf{E} \mathbf{K}^{-1} \quad \mathbf{x}_2^\mathrm{T} \mathbf{E} \mathbf{x}_1 = \mathbf{p}_2^\mathrm{T} \mathbf{F} \mathbf{p}_1 = 0 \quad (3)$$

由于E与F之间只差了相机内参,相机内参是已知的,因此实践中往往使用形式更简单的E.

### 本质矩阵E的求解

考虑到E的尺度等价性,可以用8对点来估计E,是为八点法.

对于一对匹配点,其归一化坐标 $\mathbf{x}_1 = [u_1, v_1, 1]^\mathrm{T}$ ,  $\mathbf{x}_2 = [u_2, v_2, 1]^\mathrm{T}$ .根据对极约束,有

$$(\mathbf{u}_1, \mathbf{v}_1, 1) \begin{pmatrix} \mathbf{e}_1 & \mathbf{e}_2 & \mathbf{e}_3 \\ \mathbf{e}_4 & \mathbf{e}_5 & \mathbf{e}_6 \\ \mathbf{e}_7 & \mathbf{e}_8 & \mathbf{e}_9 \end{pmatrix} \begin{pmatrix} u_2 \\ v_2 \\ 1 \end{pmatrix} = 0$$

把矩阵E展开为向量 $\mathbf{e} = [e_1, e_2, e_3, e_4, e_5, e_6, e_7, e_8, e_9]^\mathrm{T}$ ,对极约束可以写成与e有关的线性形式:

$$[u_1 u_2, u_1 v_2, u_1, v_1 u_2, v_1 v_2, v_2, u_2, v_2, 1] \cdot \mathbf{e} = 0$$

把八对点对应的 $\mathbf{x}_1, \mathbf{x}_2$ 分别代入方程中,得到线性方程组:

$$\begin{pmatrix} u_1^1 u_2^1 & u_1^1 v_2^1 & u_1^1 & v_1^1 u_2^1 & v_1^1 v_2^1 & v_2^1 & u_2^1 & v_2^1 & 1 \\ u_1^1 u_2^2 & u_1^1 v_2^2 & u_1^2 & v_1^1 u_2^2 & v_1^1 v_2^2 & v_2^2 & u_2^2 & v_2^2 & 1 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ u_1^8 u_2^8 & u_1^8 v_2^8 & u_1^8 & v_1^8 u_2^8 & v_1^8 v_2^8 & v_2^8 & u_2^8 & v_2^8 & 1 \end{pmatrix} \begin{pmatrix} e_1 \\ e_2 \\ e_3 \\ e_4 \\ e_5 \\ e_6 \\ e_7 \\ e_8 \\ e_9 \end{pmatrix} = 0$$

求得E后,对E进行SVD分解以求取R,t:设E的SVD分解为 $\mathbf{E} = \mathbf{U} \Sigma \mathbf{V}^\mathrm{T}$ ,则对应的R,t分别为:

$$\mathbf{t}^\wedge = \mathbf{U} \mathbf{R}_Z \left( \frac{\pi}{2} \right) \Sigma \mathbf{U}^\mathrm{T} \quad \mathbf{R} = \mathbf{U} \mathbf{R}_Z^\mathrm{T} \left( \frac{\pi}{2} \right) \Sigma \mathbf{U}^\mathrm{T}$$

其中 $\mathbf{R}_Z \left( \frac{\pi}{2} \right)$ 表示沿Z轴旋转90°得到的旋转矩阵.

### 对极几何的讨论

1. 尺度不确定性: 2D图像不具有深度信息,这导致了**单目视觉的尺度不确定性**.

实践中设t为单位1,计算相机运动和特征点的3D位置,这被称为单目SLAM的**初始化**.

2. 初始化的纯旋转问题: 若相机发生纯旋转,导致t为零,得到的E也将为零,会导致我们无从求解R.因此**单目初始化不能只有纯旋转,必须要有一定程度的平移**.

3. 多于8对点的情况:

对于八点法,有 $\mathbf{A} \mathbf{e} = 0$ ,其中A为一个8×9的矩阵.

若匹配点的个数多于8个,A的尺寸变化,上述方程不成立.因此转而求取最小化二次型

$$\min_{\mathbf{e}} \|\mathbf{A} \mathbf{e}\|_2^2 = \min_{\mathbf{e}} \mathbf{e}^\mathrm{T} \mathbf{A}^\mathrm{T} \mathbf{A} \mathbf{e}$$

是为最小二乘意义下的E矩阵.

### 3D-2D匹配: PnP(Perspective-n-Point)

2D-2D的对极几何方法需要8个或8个以上的点对(以八点法为例),且存在着初始化、纯旋转和尺度的问题.然而,如果两张图像中其中一张特征点的3D位置已知,那么最少只需3个点对(需要至少一个额外点验证结果)就可以估计相机运动.

在双目或RGB-D的视觉里程计中,我们可以直接使用PnP估计相机运动.而在单目视觉里程计中,必须先进行初始化,然后才能使用PnP.

PnP问题有多种解决方法:

1. 直接线性表变换(DLT): 先求解相机位姿,再求解空间点位置
2. P3P: 先求解空间点位置,再求解相机位姿
3. Bundle Adjustment: 最小化重投影误差,同时求解空间点位置和相机位姿

### 直接线性变换(DLT): 先求解相机位姿,再求解空间点位置

考虑某个空间点P 的**齐次世界坐标**为 $P = (X, Y, Z, 1)^T$ . 在图像 $I_1$  中投影到特征点的**归一化像素坐标** $x_1 = (u_1, v_1, 1)^T$ . 此时相机的位姿 $R, t$ 是未知的,定义增广矩阵 $[R|t]$ (不同于变换矩阵 $T$ )为一个 $3 \times 4$ 的矩阵,包含了旋转与平移信息,展开形式如下:

$$s \begin{pmatrix} u_1 \\ v_1 \\ 1 \end{pmatrix} = \begin{pmatrix} t_1 & t_2 & t_3 & t_4 \\ t_5 & t_6 & t_7 & t_8 \\ t_9 & t_{10} & t_{11} & t_{12} \end{pmatrix} \begin{pmatrix} X \\ Y \\ Z \\ 1 \end{pmatrix}$$

用最后一行把s消去,得到两个约束:

$$\begin{cases} t_1^T P - t_3^T P u_1 = 0 \\ t_2^T P - t_3^T P v_1 = 0 \end{cases}$$

其中 $t_1 = (t_1, t_2, t_3, t_4)^T, t_2 = (t_5, t_6, t_7, t_8)^T, t_3 = (t_9, t_{10}, t_{11}, t_{12})^T$ .  $t_1, t_2, t_3$ 为待求量.

将N对匹配的特征点代入方程中,得到线性方程组:

$$\begin{pmatrix} P_1^T & 0 & -u_1 P_1^T \\ 0 & P_1^T & -v_1 P_1^T \\ \vdots & \vdots & \vdots \\ P_N^T & 0 & -u_N P_N^T \\ 0 & P_N^T & -v_N P_N^T \end{pmatrix} \begin{pmatrix} t_1 \\ t_2 \\ t_3 \end{pmatrix} = 0$$

只需6对匹配点即可求解增广矩阵 $[R|t]$ ,若匹配点数多于6对时,可以求最小二乘解. 对于求解出的旋转矩阵 $R$ ,可以通过QR分解等手段将其投影到 $SE(3)$ 上.

### P3P: 先求解空间点位置,再求解相机位姿

[外链图片转存失败,源站可能有防盗链机制,建议将图片保存下来直接上传(img-9luduXXH-1587570602886)(1587451327097.png)]

已知3对匹配点的**世界坐标**A,B,C和**投影坐标**a,b,c,根据三角形的余弦定理,有

$$\begin{cases} OA^2 + OB^2 - 2OA \cdot OB \cdot \cos\langle a, b \rangle = AB^2 \\ OB^2 + OC^2 - 2OB \cdot OC \cdot \cos\langle b, c \rangle = BC^2 \\ OA^2 + OC^2 - 2OA \cdot OC \cdot \cos\langle a, c \rangle = AC^2 \end{cases}$$

记 $x = OA/OC, y = OB/OC, u = BC^2/AB^2, v = AC^2/AB^2$

$$\begin{cases} (1-u)y^2 - ux^2 - \cos\langle b, c \rangle y + 2uxy \cos\langle a, b \rangle + 1 = 0 \\ (1-v)x^2 - wy^2 - \cos\langle a, c \rangle y + 2wxy \cos\langle a, b \rangle + 1 = 0 \end{cases}$$

上式中,三个余弦角 $\cos\langle a, b \rangle, \cos\langle b, c \rangle, \cos\langle a, c \rangle$ 以及 $u, v$ 是已知的,可以求解出 $x, y$ ,进而求解出A,B,C三点的相机坐标. 然后根据3D-3D的点,计算相机的运动 $R, t$ .

### Bundle Adjustment: 最小化重投影误差,同时求解空间点位置和相机位姿

设相机位姿变换矩阵 $T$ ,某空间点的世界坐标 $P_i = [X_i, Y_i, Z_i]^T$ ,其投影的像素坐标为 $u_i = [u_i, v_i]^T$ ,像素位置与空间点位置的关系如下:

$$s_i u_i = K T P_i$$

由于相机位姿未知及观测点的噪声,上式存在一个误差,称为**重投影误差** $e = u_i - \frac{1}{s_i} K T P_i$ . 因此我们对重投影误差求和,寻找最好的相机位姿和特征点的空间位置,最小化重投影误差:

$$T^* = \arg \min_T \frac{1}{2} \sum_{i=1}^n \|u_i - \frac{1}{s_i} K T P_i\|^2$$

$$P_i^* = \arg \min_{P_i} \frac{1}{2} \sum_{i=1}^n ||u_i - \frac{1}{s_i} K^T P_i||^2$$

使用最小二乘优化,要分别求e对T 和P 的导数:

$$e(x + \Delta x) \approx e(x) + J \Delta x$$

- 求e对T 的导数:

当e为像素坐标误差(2维),x为相机位姿(6维)时,J 将是一个2×6的矩阵.我们来推导J的形式:

$$\text{取中间变量} P' = (T P)_{1:3} = [X', Y', Z']^T$$

使用李代数求导的扰动模型,对T 左乘微小扰动δξ,求得得到:

$$\frac{\partial e}{\partial \delta \xi} = \lim_{\delta \xi \rightarrow 0} \frac{e(\delta \xi \oplus \xi) - e(\xi)}{\delta \xi} = \frac{\partial e}{\partial P'} \frac{\partial P'}{\partial \delta \xi}$$

其中的⊕表示李代数的左乘扰动

其中第一项  $\frac{\partial e}{\partial P'}$  :

$$\frac{\partial e}{\partial P'} = - \left[ \begin{array}{ccc} \frac{\partial u}{\partial X'} & \frac{\partial u}{\partial Y'} & \frac{\partial u}{\partial Z'} \\ \frac{\partial v}{\partial X'} & \frac{\partial v}{\partial Y'} & \frac{\partial v}{\partial Z'} \end{array} \right] = - \left[ \begin{array}{ccc} \frac{f_x}{Z'} & 0 & -\frac{f_x X'}{Z'^2} \\ 0 & \frac{f_y}{Z'} & -\frac{f_y Y'}{Z'^2} \end{array} \right]$$

第二项  $\frac{\partial P'}{\partial \delta \xi}$  为变换后的点关于李代数的导数:

$$\frac{\partial P'}{\partial \delta \xi} = \frac{(T P)}{\partial \delta \xi} = (T P)^\odot = \left[ \begin{array}{cc} I & -P'^\wedge \\ 0^T & 0^T \end{array} \right]$$

在P'定义中,取出前三维,得到

$$\frac{\partial P'}{\partial \delta \xi} = [I, -P'^\wedge]$$

将两项相乘,得到了2×6的雅可比矩阵J<sup>T</sup>

$$J^T = \frac{\partial e}{\partial \delta \xi} = - \left[ \begin{array}{ccc} \frac{f_x}{Z'} & 0 & -\frac{f_x X'}{Z'^2} & -\frac{f_x X' Y'}{Z'^2} & f_x + \frac{f_x X'^2}{Z'^2} & -\frac{f_x Y'}{Z'} \\ 0 & \frac{f_y}{Z'} & -\frac{f_y Y'}{Z'^2} & -f_y - \frac{f_y Y'^2}{Z'^2} & \frac{f_y X' Y'}{Z'^2} & \frac{f_y X'}{Z'} \end{array} \right]$$

- 求e对P 的导数

### 3D-3D匹配: ICP

对于一组已配对好的3D点:

$$P = \{p_1, \cdots, p_n\}, \quad P' = \{p'_1, \cdots, p'_n\}$$

现在,想要找一个欧氏变换R,t,使得:

$$\forall i, \quad p_i = R p'_i + t$$

ICP问题的求解包含两种方式:

- 利用线性代数的求解(主要是SVD)
- 利用非线性优化方式的求解(类似于Bundle Adjustment)

### SVD方法

定义第i对点的误差项为 $e_i = p_i - (R p'_i + t)$ ,定义两组点的质心 $p = \frac{1}{n} \sum_{i=1}^n (p_i), p' = \frac{1}{n} \sum_{i=1}^n (p'_i)$

构建最小二乘问题,求取最合适的R,t.

$$\begin{aligned}\min_{\mathbf{R}, \mathbf{t}} J &= \frac{1}{2} \sum_{i=1}^n ||(\mathbf{p}_i - (\mathbf{R}\mathbf{p}'_i + \mathbf{t}))||_2^2 \\ &= \frac{1}{2} \sum_{i=1}^n ||\mathbf{p}_i - \mathbf{p} - \mathbf{R}(\mathbf{p}'_i - \mathbf{p}')||^2 + ||\mathbf{p} - \mathbf{R}\mathbf{p}' - \mathbf{t}||^2\end{aligned}$$

左边只和旋转矩阵R相关,而右边既有R也有t,但只和质心相关.因此令左边取最小值解出R,代入到右边令式子等于0求出t.

定义去质心坐标 $\mathbf{q}_i = \mathbf{p}_i - \mathbf{p}, \mathbf{q}'_i = \mathbf{p}'_i - \mathbf{p}'$ ,则优化目标可写成:

$$\begin{aligned}\mathbf{R}^* &= \min_{\mathbf{R}} \sum_{i=1}^n ||\mathbf{p}_i - \mathbf{p} - \mathbf{R}(\mathbf{p}'_i - \mathbf{p}')||^2 \\ &= \min_{\mathbf{R}} \sum_{i=1}^n -\mathbf{q}_i^T \mathbf{R} \mathbf{q}'_i \\ &= -\text{tr} \left( \mathbf{R} \sum_{i=1}^n \mathbf{q}'_i \mathbf{q}_i^T \right)\end{aligned}$$

省略数学证明,定义矩阵:

$$\mathbf{W} = \sum_{i=1}^n \mathbf{q}_i \mathbf{q}_i^T$$

对矩阵W 进行SVD分解得到:

$$\mathbf{W} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^T$$

可求解

$$\mathbf{R} = \mathbf{U} \mathbf{V}^T$$

非线性优化方法

使用李代数表达表达位姿,目标函数可以写成

$$\min_{\xi} = \frac{1}{2} \sum_{i=1}^n ||(\mathbf{p}_i - \exp(\xi^\wedge) \mathbf{p}'_i)||_2^2$$

误差项关于位姿的导数可以用李代数求导的扰动模型,计算导数得到:

$$\frac{\partial e}{\partial \delta \xi} = -(\exp(\xi^\wedge) \mathbf{p}'_i)^\odot$$

可以直接使用最小二乘优化方法求解位姿.